

План: база Meyer поиском с нуля — Россия и Беларусь, все отрасли

Редакция 4, 09.10.2026. Экономный режим. План для новой сессии: она выполняет его без доработки скриптов.

Задание владельца. Собрать максимально полную базу предприятий для Meyer — направления ООО «Руспром»: фотосепараторы (оптическая сортировка), рентген-инспекция и рентгеновская сортировка.

Результат. Excel на дропе с подписью «откуда и что внутри». По каждой компании:

- название, ИНН (или УНП), регион, сайт;
- основной и дополнительные ОКВЭД, сегмент и как он определён;
- описание и паспорт с сайта, выручка — колонкой, а не фильтром;
- номера и почты с ФИО, должностью, ролью, отметкой «ЛПР по оборудованию» и ссылкой на страницу-источник.

Экономный режим (владелец 09.10):

- модель — GPT-6 Luna везде, где качество почти не теряется;
- запросы урезаны по отдаче, измеренной пилотом.

Что готово. 08–09.10 весь конвейер прогнан пилотом на трёх регионах: Краснодарский край, Свердловская и Минская области. Скрипты рабочие и параметризованы набором. Новой сессии остаётся выполнить часть Б по шагам.

Как устроен файл:

- часть А — справочник: прочитать до старта;
- часть Б — шаги по порядку;
- часть В — бюджет и время;
- часть Г — что может пойти не так и что делать;
- часть Д — итоги пилота, справочно.

Часть А. Справочник

А1. Общие правила

1. **CLAUDE.md** в корне репозитория — прочитать первым.

- **Холд рассылки.** Ни писем, ни звонков, ни форм; почты не проверять отправкой.
- **Тяжёлая работа модели** — только через провайдерский API.
- **Результаты** — на сервер (*.jsonl с fsync) и копия на дроп. Песочница при рестарте откатывается, сервер — нет.
- **Слово владельца — истина.** Решённое (A3) не переспрашивать.

2. **Писать владельцу** по-русски, коротко, с цифрами.

3. **Справочно:**

- meyer-zaprosy/KATALOG.md — каталог запросов;
- meyer-zaprosy/BENCH-MODELI.md — сравнение моделей;
- PLAN-AGENCY-POISK-NOMEROV.md, раздел 4 — проверки перед выдачей.

A2. Сервер владельца

Доступ

- **Репозиторий** `kirillrand4-alt/avto`, ветка `claude/detailed-study-7j12hg`. Скрипты лежат в `seo-texts/server/`, в `main` их нет.
- **Переменные сессии:** `DROP_URL`, `DROP_TOKEN`, `JOB_SECRET`, `PROVIDER_API_KEY`, `PROVIDER_BASE_URL`. Проверять только наличие, значения не печатать.
- **Секреты сервера** (`XMLRIVER_*`, `DADATA_TOKEN`, ключ провайдера) лежат в окружении панели, скрипты берут их сами.
- **Прокси checko** — только в `C:\sender\server\checko-proxies.json`. В git и чат не выводить.
- **Права.** `.claude/settings.json` ветки разрешает раннер. Если режим Auto блокирует запуск кода на сервере, нужен режим «Accept edits».

Инструменты (запускать из `seo-texts/server/`)

Что	Команда	Тонкости
Выполнить скрипт на сервере	<code>timeout 900 python3 run_script_on_server.py мой.py 600</code>	Скрипт выполняется питоном панели с её окружением. Итог печатать после <code>===ИТОГ===</code> , читать через <code> sed -n '/===ИТОГ===/, \$p'</code> . Предел — 30 минут. Скрипт с секретами держать в песочнице, не в репозитории
Положить модуль на сервер	<code>python3 dostavit.py файл.py 'C:\sender\server\файл.py'</code>	Успех — "положено": <code>true</code> , при <code>false</code> повторить. Предел ~700 КБ, больше — через дроп
Дроп	<code>bash drop_client.sh list / up файл / down имя</code>	На сервере — <code>C:\seostat\drop\drop-storage\</code>
Долгий процесс	лаунчер <code>_pusk_*.py</code>	Рорен с флагами <code>0x08 0x200</code> , лог <code>имя_ДДММ-ЧЧММ.log</code> . Окружение набора передаётся в <code>env=</code> (образец — <code>_pusk_pilot_razbor.py</code>). Локальный вызов лаунчера «висит»: <code>timeout 150 ...; echo ok</code> , затем проверка статусом
Статус	<code>_status_pilot.py</code> (копия под свой набор)	Строки <code>jsonl</code> , шаги конвейера, хвосты логов, живые процессы. Время сервера — МСК
Остановка	<code>_ostanov_pilot_vse.py</code>	Фильтр — <code>CommandLine -like '*server\имя.py*'</code> . Грабля: стоп-скрипт, в имени которого есть имя цели, убивает сам себя
Проверка импорта «как в фоне»	<code>_test_importy_pilot.py</code>	Перед каждым детач-запуском после правок: раннер видит модули из <code>_tmp</code> , фон — нет
xmlriver	<code>_balans_xmlriver.py</code> (на сервере)	Баланс в рублях
Провайдер	<code>python3 _rashod_provider.py <метка></code> (из сессии); <code>_probe_provider.py</code> — жив ли шлюз	Счётчик расхода ключа в \$ за всё время. Ключом параллельно пользуются другие сессии владельца (фон 5–7 \$ в час, 09.10), поэтому разница замеров — это верхняя граница, а не цена шага. Точные цены по моделям — в журнале расходов кабинета <code>router.cheap</code> (просить владельца скриншот)
Качество обхода	<code>_pilot_kachestvo.py</code> , <code>_pilot_pustye.py</code> , <code>_pilot_chistka_pustyh.py</code>	Доля открытых сайтов, ролей и ЛПР. Записи, испорченные сбоем провайдера, удалить до перезапуска

Пути на сервере

- `C:\sender\server\` — скрипты, `*.jsonl`, логи.
- `C:\sender\enrich.db` — компании, ОКВЭД, контакты, паспорта (`site_facts`).

- C:\sender\obzvон-index.db — 161 тыс. юрлиц (КЦ и Meyer).
- C:\sender\sender.db — запреты панели: сделки и конкуренты, исключаются всегда.
- C:\sender_ops\ak\фнс\revexp.zip — доходы ФНС.
- C:\seostat\drop\pagecache\ — кэш страниц обхода, из него собирается паспорт. 100 тыс. сайтов — ~23 ГБ, на диске свободно 139 ГБ.

Привычки (каждая — урок пилота)

1. **Резюм везде.** Любой шаг можно остановить и запустить снова, сделанное он пропустит.
2. **Ошибка — это не «пусто».** «Закончились средства» у xmlriver или credit wallet quota insufficient у провайдера — это сразу стоп конвейера и сообщение владельцу (подробно — часть Г).
3. **Проверки каждые 30-60 минут:** статус, доля ошибок, траты. Опрос — фоновым циклом, а не sleep.
4. **Коммитить по ходу** в ту же ветку. В тексте коммитов модели не упоминать.

А3. Решения владельца (не переспрашивать)

Сегменты — по основному ОКВЭД. Таблица кодов — pilot_otbor.СЕМ, исключения — pilot_otbor.ИСКЛ.

Группа	Сегменты
Пищевые	весь раздел 10, кроме рыбы 10.20: мясо 10.1, молоко 10.5, мукомолье, крупы и рис 10.61, МЭЗ 10.41, овощи, фрукты, орехи и семечка 10.39, ягоды и соки 10.32, картофель 10.31, кондитерка 10.7 и 10.82, кофе и чай 10.83, специи 10.84, корма 10.9
Агро	01.11, 01.12, 01.13, 01.15, 01.16, 01.25, 01.28, 01.63; семеноводство 01.64; свой убой 01.46, 01.47; молочное скотоводство 01.41; дикоросы 02.30; элеваторы 52.10; зерновые терминалы 52.24
Опт и фасовка	опт зерном 46.21; опт орехами, сухофруктами, специями, крупами 46.31, 46.37, 46.38, 46.39; фасовщики и СТМ 82.92
Экспортёры	без ОКВЭД: ВЭД на сайте и в реестрах, сегмент — по товару
Напитки	только солод 11.06
Непищевые	переработка пластика 38.32 и 22.2; полимеры 20.16 и 20.17; нерудные 08.11, 08.12, 08.9; соли и химсырьё 08.91, 08.93, 20.13, 20.15; стекло 23.1; вторсырьё 38.32 и 46.77; дерево 16.1 и 16.2; уголь 05; руды 07 и 08.99; цветная металлургия и лом 24.4, 24.53
Не брать	рыба (03, 10.20); напитки (11, кроме солода); ТКО и мусоросортировка (38.11, 38.21, 38.22); бумага 17; текстиль 13; шины 22.11; электронный лом; фарма 21; огнеупоры 23.2; керамика 23.3; абразивы 23.91

Дополнительный ОКВЭД. Если основной код вне сегментов, а дополнительный в сегменте, компания проходит только после подтверждения сайтом (шаг pilot_dop_proverka.py). Неподтверждённые — на лист «Не вошли».

Выручка — колонка, а не фильтр. ИНН только из каталогов без сведений о доходе — на лист «Ниже порога». Сделки, запреты панели, конкуренты и ликвидированные исключаются всегда.

Не выкидывать

- **ИНН не определён, а сайт подходит под Meyer** — компания идёт с ключом САЙТ: <домен>. Подходит ли, решает модель.
- **ОКВЭД не найден, ИНН со своего сайта** — сегмент определяет модель по сайту.
- **ОКВЭД не найден, ИНН из каталога** — лист «Ждут ОКВЭД», добор на следующие сутки (шаг Б10).
- **Сайт не открылся, открылся без контактов или без ЛПР** — в <набор>-zenka.json и на лист «Не открылись (для Зенки)» с CSV. Владелец откроет такие сайты через ZennoPoster.

Беларусь — все сегменты, как Россия.

- Ключ — `BY<УНП>`, УНП берётся с сайта.
- Номера `+375` и `8 0XX` понимают обход и агенты.
- Подходит ли сайт, решает модель.
- `egr.gov.by` с сервера не отвечает: название берётся с сайта, выручка неизвестна.

Роли и ЛПР. ЛПР — тот, кто отвечает за покупку оборудования или влияет на неё. Колонки листа «Контакты»:

- «Должность (как на сайте)»;
- «Роль» — справочник `kc_kontakty.РОЛИ`;
- «ЛПР по оборудованию» — да / возможно / нет;
- «Почему ЛПР».

ЛПР	Роли
«да» всегда	Руководитель; Техдиректор / главный инженер; Механик / энергетик / ремонт; Производство; Технолог; Качество / лаборатория (владелец 09.10: «оставь»); Закупки / снабжение
«да» в своих сегментах	Агрономия и Хранение — у семеноводов, элеваторов, ягод и орехов; Обогащение — у руд, угля и нерудных
«возможно»	Коммерция, Прочее
«нет»	Продажи, Финансы, Кадры, Общий номер

Порядок строк в Excel:

1. ЛПР «да» с ФИО.
2. ЛПР «да» без ФИО.
3. «Возможно».
4. Прочие.
5. Общие.

Внутри группы мобильный и добавочный идут выше городского.

Почты — как номера

- Источники — `mailto:` и текст; защита от сборщиков (`[at]`, «собака») снимается (`kc_pochty.py`).
- Своя почта — на домене сайта. Публичная (`mail.ru` и т. п.) берётся только со своей страницы.
- Роль у почты определяется, как у номера, по подписи рядом. Если подписи нет, а адрес своего домена «говорящий» (`snab@`, `zakupki@`, `otk@`, `glavmeh@`, `director@`), роль ставится по адресу.
- Агенты собирают почты так же, как номера, и скрипт проверяет их по открытой странице.
- Чужой домен, веб-студия, `pogetry`, заглушки — в «Снято».

Правила качества (нарушать нельзя)

1. **Источник номера или почты** — только живая страница:
 - сайт самой компании;
 - сайт холдинга, с пометкой;
 - карточка закупки, где компания — заказчик.`chеско`, `rusprofile`, СМИ и каталоги годятся только для поиска компаний и ОКВЭД.
2. **Вывод модели или агента** скрипт проверяет по заново скачанной странице.
3. **В «Снято» с причиной:** чужие контакты, горячие линии, дилеры, ведомства, другие заводы группы.

4. **Сайт подтверждён**, если на нём есть ИНН, или модель ответила «та же / группа», или агент привёл цитату. Вдобавок опровергатель не должен найти ловушку. Отклонённый сайт в колонку «Сайт» не ставится; «сомневаюсь» — лист «Спорные».
5. **В выдаче 0 сделок и 0 запретов панели**. Повторы с файлами Meyer 1–6 (на дропе) отмечаются колонкой.

Часть Б. Шаги по порядку

Набор в примерах — meyer7. Каждый шаг заканчивается проверкой; не прошла — дальше не идти.

Б1. Окружение и балансы

1. Подтянуть ветку: `git fetch origin claudedetailed-study-7jl2hg && git checkout claudedetailed-study-7jl2hg`.
2. Проверить сервисы:
 - `bash drop_client.sh list` — список файлов;
 - `_probe_provider.py` — ответ «ok»;
 - `python3 _rashod_provider.py` старт — первый замер расхода.
3. Проверить xmlriver: `_balans_xmlriver.py` на сервере.

Проверка: на xmlriver ≥ 5 тыс. ₽. Баланс провайдера через API не виден — владелец подтверждает, что на счёте не меньше суммы из части В. **Если нет:** сообщить владельцу точные суммы (часть В) и ждать пополнения. Без денег не начинать: обрыв посреди шага портит записи.

Б2. Доставка и лаунчеры

1. Доставить все `.py` из `seo-texts/server/` через `dostavit.py` (каждый — "положено": `true`).
2. Скопировать под набор (`sed: pilot → meyer7`, и ещё раз `→ meyer7t` для пробы Б3): лаунчеры поиска, разбора и конвейера, `_status_pilot.py`. В `env=` лаунчеров указать `POISK_NABOR=meyer7, KC_NABOR=meyer7, POISK_REGIONY_SVERKI=все`.
3. Запустить `_test_importy_pilot.py`.

Проверка: импорт без ошибок.

Б3. Тестовая партия — первым делом (владелец 09.10)

Цель — до полного прогона показать владельцу качество итога: вся цепочка на случайных запросах по всем регионам, на выходе 100 самых разных компаний с сайтами, номерами, почтами и ЛПР.

1. Задачи — 1 500 случайных задач экономного режима поровну по 94 регионам (87 РФ — без Ненецкого и Чукотского АО — и 7 РБ: 6 областей и Минск) и «без региона», ~50 ₽:

```
python3 pilot_zadachi.py проба meyer7t 1500
bash drop_client.sh up meyer7t-zadachi.json
```

2. Запустить поиск и конвейер набора meyer7t теми же лаунчерами, что в Б5 и Б7 (ранний разбор не нужен). Модели, пороги агентов и проверки — как в полном прогоне.
3. Собрать Excel набора, как в Б11 (набор meyer7t), и выбрать 100 самых разных компаний:

```
python3 proba_100.py MEYER-7t.xlsx PROBA-100.xlsx
```

Выбор — по кругу «сегмент → регион», обе страны. Компании, у которых контактов не нашлось, тоже попадают в выборку: картина должна быть честной.

4. На дроп — `PROBA-100.xlsx`. Владелец — сводка из листа «Сводка» (доли с сайтом, номером, почтой, ЛПР), траты и время пробы.

Ожидаемо: 1-2 тыс. компаний в партии, ~5 часов, ~\$10-20 провайдера и ~100 ₽ xmlriver.

Стоп. Полный прогон (Б4 и дальше) — только после ответа владельца по пробе. Замечания исправить; если правки касаются шагов конвейера — перепрогнать пробу.

Б4. Задачи поиска

```
python3 pilot_zadachi.py экономный meyer7 600 200
bash drop_client.sh up meyer7-zadachi.json
```

Проверка: ~50 тыс. задач. Виды `беларусь_*` идут только на регионы РБ.

Б5. Поиск (~12 ч)

Запустить лаунчер поиска.

- Режим экономный: топ-600 шаблонов × 94 региона (87 РФ + 7 РБ), Google — топ-200, запросы без региона — все с ненулевой отдачей.
- Поток «регион × вид» останавливается, если 20 запросов подряд дали меньше 3 новых сайтов.
- Поиск держит резерв `PIL0T_REZERV` (350 ₽) и сам встаёт, если деньги на исходе.

Проверка через 15 минут: строки в `meyer7-serp.jsonl` растут, ошибок меньше 2%.

Б6. Ранний разбор (через ~1 ч после старта поиска)

Запустить лаунчер разбора параллельно с поиском. Разбор выдачи: сайт → ИНН, УНП, юрназвание.

Страницы каталогов скачиваются не все:

- только справочники ИНН и УНП и B2B-каталоги, с лимитом 60 и 40 страниц на домен;
- страницы с ИНН в адресе не скачиваются.

Проверка: растёт `meyer7-razbor.jsonl`.

Б7. Конвейер (запустить сразу после Б6; сам ждёт окончания поиска и раннего разбора)

Лаунчер `_pusk_meyer7_konveyer.py`, оркестратор `pilot_konveyer.py`. Шаги идут сами, по порядку:

#	Шаг	Модель	Что делает	Потоков
0	<code>poisk_razbor.py</code>	—	дочищает разбор после поиска	40
1	<code>pilot_otbor.py</code>	Luna	ОКВЭД → сегмент; без ИНН, без ОКВЭД и белорусы — модель «подходит?»; сверка с реестром	—
2	<code>pilot_sayty_dobor.py</code>	—	сайт по названию для компаний из каталогов (xmlriver)	8
3	<code>kc_kontakty.py</code>	Luna	обход: контакты, руководство, отделы, закупки, второй уровень меню, пагинация, карточки сотрудников; номера РФ и РБ, почты, роли	24

#	Шаг	Модель	Что делает	Потоков
4	<code>pilot_dop_proverka.py</code>	Luna	подтверждение доп. ОКВЭД по сайту	—
5	<code>pilot_pasport.py</code>	GPT-5.6 Luna (FACTS_MODEL; GPT-6 Luna на паспорте хуже — часть В)	паспорт сайта из кэша страниц обхода (13 полей), запись в <code>enrich.db</code>	24
6	<code>kc_audit.py</code>	Luna	чей номер или почта	24
7	<code>kc_audit2.py</code>	—	чей сайт по ИНН на страницах	—
8	<code>kc_sayt_proverka.py</code>	Sol	модель о сайте: та же компания, группа или чужой	24
9	<code>kc_opроверzhenie.py</code>	Luna	опровергатели; у 20% — второй вызов	24
10	<code>kc_glubokiy_vhod.py</code>	—	вход агентам: без сайта + опровергнутые	—
11	<code>kc_agent_glubokiy.py</code>	Sol	агенты: ищут сайт или холдинг, номера и почты ЛПР; компании с выручкой от 500 млн ₽ (KC_AGENT_OT)	30
12	<code>kc_agent_glubokiy.py:хвост</code>	Luna	агенты для выручки 120–500 млн ₽ (KC_AGENT_OT_HVOST); ниже 120 млн агенты не находят почти ничего (часть Д)	30
13	<code>kc_agent_pereproverka.py</code>	Luna	перепроверка найденного агентами	24

Поведение оркестратора:

- падение шагов 0–3 останавливает конвейер, остальные шаги повторяются один раз;
- статус пишется в `meyer7-konveyer.json` и на дроп;
- продолжить с шага N: `PILOT_S_SHAGA=N` (образец — `_pusk_pilot_konveyer_s3.py`).

Б8. Контроль по ходу (каждые 30–60 мин, весь прогон)

- Статус-скрипт набора: шаги, хвосты логов, доля сбоев.
- `_balans_xmlriver.py` и `_rashod_provider.py`: траты против части В. Счётчик провайдера включает траты других сессий владельца, поэтому при подозрении на перерасход (больше чем на 30%) — попросить у владельца журнал расходов кабинета и сообщить.
- После шага 3 — `_pilot_kachestvo.py`: открылось $\geq 90\%$ сайтов, роли есть у $\geq 95\%$ номеров.

Б9. Промежуточный отчёт владельцу (после шага 1, конвейер не останавливать)

- Сколько компаний по сегментам.
- Сколько ждут ОКВЭД.
- Сколько сайтов ушло Зенке.
- Полнота по реестру: доля компаний наших баз, найденных поиском.

Б10. Добор ОКВЭД (раз в сутки, пока лист «Ждут ОКВЭД» не пуст)

DaData даёт 10 тыс. запросов в сутки, лимит общий с `news-scan`. Когда основной прогон конвейера дошёл до конца, после полуночи МСК перезапустить его с шага 1 (`PILOT_S_SHAGA=1`). Отбор доберёт ОКВЭД, а остальные шаги обработают только новые компании.

Когда остаток перестаёт уменьшаться (DaData не знает ИНН), он остаётся на листе как есть.

Б11. Excel

```
python3 pilot_analiz.py <папка> meyer7-analiz.json meyer7
python3 pilot_xlsx.py <папка> <папка файлов Meyer 1-6> meyer7-analiz.json pilot-slabye.json
MEYER-7.xlsx meyer7
```

Файлы набора скачать с дропа; файлы Meyer 1-6 — тоже с дропа (1-meyer-... ... 6-meyer-poisk-0810.xlsx).

Листы:

- Сводка, Слабые места, Тест поиска, Полнота;
- Компании (с паспортом), Контакты;
- Снято, Спорные, Пояснения агентов;
- Не вошли (доп. ОКВЭД), Не открылись (для Зенки) + CSV;
- На решение, Ниже порога, Ждут ОКВЭД.

Б12. Проверки перед выдачей

1. Раздел 4 PLAN-AGENCY-POISK-NOMEROV.md.
2. 20 строк глазами по ссылкам-источникам.
3. 30 вердиктов опровергателей: ложных больше 10% — ужесточить промпт и перезапустить шаг 9.
4. 0 сделок и запретов панели.

Б13. Выдача

Excel и CSV для Зенки — на дроп. Владелец — сообщение: что внутри, цифры, траты xmlriver и провайдера (по счётчику — верхняя граница, точнее — журнал кабинета).

Б14. Колонка «Есть в Битрикс» (когда владелец пришлёт deals_inn.csv)

python3 dobavit_bitrix.py deals_inn.csv MEYER-7.xlsx MEYER-7-bitrix.xlsx → дроп. В выгрузке Битрикса на дропе колонки ИНН нет, поэтому нужен именно этот файл от владельца.

Часть В. Бюджет и время

Оценка на ~100 тыс. компаний в списке (реально может выйти 60–120 тыс., суммы меняются пропорционально). Цены провайдера — по журналу расходов кабинета router.cheap 09.10:

- GPT-6 Luna (маршрут Pro/Enterprise) — ~\$0,0002–0,0004 за вызов на ~3 тыс. токенов;
- GPT-6 Sol — ~\$0,004–0,006 за вызов на 7–11 тыс. токенов (шлюз добавляет к каждому вызову Sol ~4 тыс. скрытых кэшированных токенов).

Провайдер

Шаг	Модель	Объём	Сумма
Отбор: «подходит под Meyer?»	Luna	~140 тыс. вызовов	~\$30
Обход: роли, ЛПР, описание	Luna	~75 тыс. компаний	~\$90
Доп. ОКВЭД, чей номер, опровергатели, перепроверка	Luna	~150 тыс. вызовов	~\$60
Паспорт сайта	GPT-5.6 Luna	~55 тыс. сайтов	~\$150–300

Шаг	Модель	Объём	Сумма
Проверка сайта	Sol	~40 тыс. вызовов	~\$200
Агенты от 500 млн ₽	Sol	~1,5-2 тыс. компаний × ~\$0,08	~\$150
Агенты 120-500 млн ₽	Luna	~4 тыс. компаний × ~\$0,005	~\$20
Итого			≈ \$0,7-0,85 тыс. (вилка \$0,6-1,1 тыс.)

xmlriver (~0,025 ₽ за запрос)

Статья	Запросов	Сумма
Поиск (Б5)	~65-70 тыс.	~1,7 тыс. ₽
Сайты по названию (шаг 2)	~35 тыс.	~0,9 тыс. ₽
Агенты (~4 поиска на компанию)	~25 тыс.	~0,6 тыс. ₽
Отбор и прочее	—	~0,3 тыс. ₽
Итого		≈ 3,5 тыс. ₽ ; на балансе к старту — 5 тыс. ₽ с запасом

DaData — бесплатно, но 10 тыс. ИНН в сутки (лимит общий с news-scan). Добор ОКВЭД (Б10) идёт параллельно, 3-5 суток.

Время — ~3,5-4 суток работы сервера

Этап	Часы
Тестовая партия (Б3), затем ожидание ответа владельца	~5
Поиск (Б5), разбор идёт параллельно	~12
Хвост разбора, отбор, сайты по названию	~8
Обход (150 компаний в минуту)	~9
Доп. ОКВЭД, паспорт, чей номер, чей сайт	~12
Проверка сайта, опровергатели	~14
Агенты: Sol ~15 мин и Luna ~5 мин на компанию, 30 потоков	~27
Перепроверка, Excel, проверки	~5

Как сэкономить, если нужно

- Агенты целиком на Luna (KC_AGENT_OT=1e15 — проход Sol пустой): ~\$30 вместо ~\$170. Теряется примерно 40% номеров ЛПР у компаний с выручкой 0,6-2 млрд.
- Паспорт на GPT-6 Luna проверен 09.10 на 20 компаниях и НЕ берётся: строк фактов на 14% меньше (386 против 448), подтверждено текстом сайта 94% против 98%, хуже мощности, контроль качества, география. Экономия была бы ~\$100.

Для сравнения: все модельные шаги на Fable через router.cheap — ~\$70 тыс.; агенты на всех компаниях без порога выручки на Sol — ещё ~\$1,5 тыс. и ~6 суток почти без находок.

Часть Г. Что может пойти не так

Признак	Что делать
xmlriver: «Закончились средства»	Поиск встаёт сам по резерву. Остальные шаги — остановить (<code>_ostanov_pilot_vse.py</code>), сообщить владельцу сумму, после пополнения продолжить с того же шага

Признак	Что делать
Провайдер: credit wallet quota insufficient	Стоп конвейера. Записи без ролей и описаний удалить (<code>_pilot_pustye.py</code> → <code>_pilot_chistka_pustyh.py</code>), после пополнения продолжить с шага
Обрывы связи сервер → шлюз (WinError 10054)	Шаги повторяют вызов сами. Если сбоев больше 5%, гнать вызовы модели из сессии (образец <code>pilot_bench_lokalno.py</code>)
DaData выбран (10 тыс. в сутки)	Не ждать: <code>P0ISK_NE_ZHDAT=1</code> , компании копят на «Ждут ОКВЭД», добор — Б10
Агенты идут медленно (Sol — ~15 мин на компанию)	30 потоков (<code>KC_AGENT_P0T0K0V</code>), можно до 40. Больше не ставить: <code>xmlriver</code> и сайты начинают отказывать
Перерасход больше 30%	Сообщить владельцу. Агентов можно урезать порогами выручки (<code>KC_AGENT_0T</code> , <code>KC_AGENT_0T_HV0ST</code>)
Контейнер сессии перезапустился	Всё работает на сервере. Состояние брать из <code>meyer7-konveyer.json</code> и логов, не из песочницы. Фоновые наблюдатели в сессии перезапустить
Чужие сайты в списке (СКРИН, газеты, министерства)	Ловят шаги 7-9. Обход по ним тратит немного времени Luna: это дешевле, чем отдельная проверка до обхода
Модель молчит (шлюз шлёт только ping)	<code>GP.call</code> уходит на запасную. Конвейер ставит запасной GPT-6 Luna (<code>PROVIDER_FALLBACK_CHEAP</code>), а не Claude Haiku: тот дороже и со скрытым довеском шлюза. В тесте паспорта 09.10 — 3 подмены на 40 вызовов
Раннер: предел 30 минут	Всё долгое — только через лаунчеры <code>_pusk_*</code>

Часть Д. Итоги пилота (справочно)

Пилот 08-09.10. 3 региона, 24,9 тыс. выдач, ~620 ₺ xmlriver.

- **Список** — 11 017 компаний:
 - 8 266 с ИНН, из них 1 252 — по доп. ОКВЭД, 597 — сегмент по сайту, 150 — из реестра;
 - 2 289 сайтов без ИНН, подошли под Meyer;
 - 462 белоруса.
- **Обход:** 8 391 компания. Сайт открылся у 6 082, номера нашлись у 5 678. Для Zenki — 1 191 сайт.

Что пилот изменил в плане. Всё уже учтено в частях А и Б; подробно — `pilot-slabye.json` и лист «Слабые места».

- xmlriver отдаёт 10 результатов на страницу. Стр. 2-3 дают +16% компаний, Google — +10%.
- Остановка «10 пустых запросов — стоп» теряет 40-50% компаний. Поэтому запросы отобраны по отдаче, а остановка мягкая.
- Поиск находит 43% компаний наших баз. Поэтому сверка с реестром обязательна.
- Доп. ОКВЭД без подтверждения сайтом пропускает мусор.
- Обход ускорен с 5 до ~150 компаний в минуту: 24 потока, без checko, ЕИС только от 1 млрд.
- Fable и Orus через шлюз получают скрытый довесок 70-80 тыс. токенов (\$0,14-0,31 за вызов). Luna — 94% совпадения с эталоном при \$0,0002 за вызов, Sol — 96% при \$0,007.

Сравнение агентов (09.10). Одни и те же компании без подтверждённого сайта, 100 штук равномерно по выручке (медиана 59 млн ₺). Luna прошла все 100, Sol — 41 (остановлена по

бюджету). Номер принимается, только если он есть на открытой странице подтверждённого сайта завода или холдинга.

На 41 общей компании	Luna	Sol
Компаний с номером	32%	37%
Компаний с номером ЛПР	15%	20%
Номеров принято / из них ЛПР / с ФИО	23 / 7 / 3	36 / 13 / 10
Номеров-выдумок снято скриптом	6	3
Время на компанию	~5 мин	~17 мин
Цена на компанию (по токенам)	~\$0,005	~\$0,08

Выручка (места в выборке)	Luna: с номером / с ЛПР	Sol: с номером / с ЛПР
2,2-606 млрд (1-10)	9 / 5 из 10	8 / 5 из 10
0,7-1,9 млрд (11-20)	0 / 0 из 10	4 / 2 из 10
264-609 млн (21-30)	3 / 1 из 10	2 / 1 из 10
121-246 млн (31-41)	0 / 0 из 11	1 / 0 из 9
27-112 млн (42-60)	3 / 0 из 19	—
до 25 млн (61-100)	0 / 0 из 40	—

Выводы:

- агенты окупаются только у крупных: ниже ~120 млн ₽ обе модели не находят почти ничего — агентов там нет;
- Sol находит примерно в 1,5 раза больше номеров ЛПР и втрое больше ФИО, заметнее всего на выручке 0,6-2 млрд. Решение владельца 09.10 («средний вариант»): от 500 млн — Sol, 120-500 млн — Luna, проверка сайта — Sol;
- ссылки на номера ЛПР владелец проверил 09.10. Найденная ошибка Sol — общий номер закупок НЛМК приписан ещё трём директорам, рядом с номером их фамилий нет. Исправлено правилом: номер с разными ФИО у агента — ФИО снимаются, роль остаётся;
- счётчик расхода ключа в тесте показал ~\$15, но ключом в это время пользовались другие сессии. По токенам тест стоил ~\$4.

Остаётся рисками:

- egr.gov.by с сервера недоступен;
- «реестр» — только наши базы (161 тыс. юрлиц), полного реестра ОКВЭД x регион нет.